



RELATÓRIO TÉCNICO DE PROJETO FINAL

Sistema Inteligente - AgroScan AI – Diagnóstico Automatizado de Fitopatologias

Ana Julia Vieira Lidório
Caio dos Santos Lopes
Lara da Rosa Dondossola
Maine Calabrezi de Souza

1. Visão Geral e Definição do Problema

A identificação tardia de doenças em culturas agrícolas gera perdas severas na produtividade e no rendimento econômico de pequenos e médios produtores. Diagnósticos visuais incorretos geram o uso indevido de defensivos agrícolas, elevando custos e o impacto ambiental. Diante desse cenário, o projeto AgroScan AI propõe uma solução baseada em inteligência artificial para o apoio à tomada de decisão no campo.

Especificações do Projeto:

- **Técnica de IA Utilizada:** Machine Learning.
- **Problema e Relevância:** Diagnóstico ineficiente e demorado de patologias que comprometem colheitas inteiras e afetam a segurança alimentar.
- **Persona do Usuário:** Produtores rurais, agrônomos e técnicos agrícolas que buscam suporte rápido para tomadas de decisão fitossanitárias.
- **Decisão Apoiada pelo Sistema:** O sistema apoia a decisão de manejo agrícola,

indicando se a planta está saudável ou identificando a patologia detectada em suas folhas, permitindo intervenções rápidas e localizadas.

- **Limites e Suposições:** O modelo assume que as imagens capturadas possuem foco e iluminação adequados sobre as folhas, com fundo minimamente neutro. O escopo atual limita-se estritamente ao diagnóstico de três culturas específicas: Pimentão, Batata e Tomate

2. Dados e Mapeamento Fitopatológico

O projeto utiliza o banco de dados público [Plant Village](#), contendo imagens reais de folhas de plantas. O volume de dados usado no projeto cumpre o requisito mínimo exigido de mais de 300 registros com variáveis-alvo consolidadas para classificação por Machine Learning.

Cultura	Nome em Português (Classe Alvo)	Diretório Original (Dataset)
Pimentão	Pimentão — Mancha bacteriana	Pepper___bell___Bacterial_spot
Pimentão	Pimentão — Saudável	Pepper___bell___healthy
Batata	Batata — Pinta preta / Alternariose	Potato___Early_blight
Batata	Batata — Requeima	Potato___Late_blight
Batata	Batata — Saudável	Potato___healthy
Tomate	Tomate — Mancha bacteriana	Tomato___Bacterial_spot
Tomate	Tomate — Pinta preta / Alternariose	Tomato___Early_blight
Tomate	Tomate — Requeima	Tomato___Late_blight
Tomate	Tomate — Bolor cinzento / Mofo das folhas	Tomato___Leaf_Mold
Tomate	Tomate — Septoriose	Tomato___Septoria_leaf_spot
Tomate	Tomate — Ácaro-rajado	Tomato___Spider_mites_Two-spotted_spider_mite
Tomate	Tomate — Mancha-alvo	Tomato___Target_Spot
Tomate	Tomate — Vírus do enrolamento amarelo da folha	Tomato___Tomato_Yellow_Leaf_Curl_Virus
Tomate	Tomate — Vírus do mosaico do tomateiro	Tomato___Tomato_mosaic_virus

Cultura	Nome em Português (Classe Alvo)	Diretório Original (Dataset)
Tomate	Tomate — Saudável	Tomato___healthy

Como etapa de consistência e integridade do fluxo de entrada, uma segunda base de dados complementar foi mapeada para treinar o modelo de triagem biológica. O banco de dados [Leaf vs Non-Leaf Images](#). Esse conjunto garante que imagens sem relação com o tema ou que não sejam folhas sejam descartadas antes da análise fitopatológica.

Cultura / Alvo	Classe Analítica (Classe Alvo)	Descrição do Domínio de Dados
Triagem Estrutural	Folha	Imagens focadas em estruturas foliares das culturas escopadas
Triagem Estrutural	Não-Folha	Objetos diversos, ferramentas, solos, animais ou paisagens gerais

3. Processamento com Inteligência Artificial

O ecossistema computacional do **AgroScan AI** opera com uma pipeline de processamento em cascata, composta por dois modelos neurais especializados atuando de forma síncrona. O primeiro atua como um filtro analítico de validação da imagem e o segundo realiza a inferência diagnóstica final (Mapeamento das Patologias).

Ambos os motores baseiam-se na técnica de *Machine Learning* aplicada à Visão Computacional, utilizando a arquitetura de última geração **YOLO (You Only Look Once)** em sua vertente de classificação de imagens (**YOLO-cls** via biblioteca **ultralytics**).

Aplicamos Fine-Tuning (ajuste fino) em um modelo YOLO pré-treinado. Essa técnica transfere o aprendizado de características visuais gerais (arestas, texturas e formas) para a tarefa especializada de identificar lesões foliares, colorações anômalas e padrões geométricos causados por fitopatógenos.

Configuração, Características e Estrutura dos Modelos

Ambas as redes neurais integradas ao backend (o modelo de triagem **folha_naofolha.pt** e o modelo fitopatológico **best.pt**) baseiam-se na arquitetura **YOLO (YOLO-cls** via biblioteca **ultralytics**) e compartilham diretrizes homogêneas de configuração e

compilação:

- **Estrutura de Entrada:** Realiza o redimensionamento automático das imagens para otimização espacial dos tensores de entrada antes da inferência.
- **Técnica de Aprendizado:** Foi aplicado *Fine-Tuning* (ajuste fino) sobre os pesos pré-treinados da rede YOLO. Esse processo otimizou as camadas convolucionais para extrair características visuais específicas — como formas geométricas, texturas orgânicas e padrões de nervuras foliares no modelo de triagem, e lesões ou colorações anômalas no modelo de doenças.
- **Camadas de Customização:** Adição de uma camada de *Global Average Pooling* para redução de dimensionalidade, seguida de uma camada de *Dropout* (com taxa de 0.2) para regularização estrutural, atuando como um protetor contra o sobreajuste (*overfitting*).
- **Camada de Saída, Incerteza e Probabilidade:** A camada densa final utiliza a função de ativação *Softmax* para gerar uma distribuição probabilística bem comportada entre as classes mapeadas. No modelo de triagem, isso resulta em um cálculo binário, enquanto no fitopatológico distribui-se entre as 15 classes alvo. Esse mecanismo permite extrair o nível exato de confiança para a classe prevista com maior probabilidade (**top1conf**).
- **Compilação e Otimização:** Uso do otimizador **Adam** com taxa de aprendizado controlada e minimização baseada na função de perda *Categorical Crossentropy* (aplicada de forma binária na triagem e multiclasse no diagnóstico).
- **Exportação e Infraestrutura:** Os modelos finais treinados foram exportados no formato nativo e serializado do PyTorch (**folha_naofolha.pt** e **best.pt**). Isso garante total portabilidade, carregamento ultra rápido em memória via Streamlit e baixíssima latência de inferência, reduzindo o tempo de resposta para o usuário final a poucos milissegundos.

4. Interface Obrigatória e Fluxo de Funcionamento

Cumprindo a premissa fundamental e obrigatória do projeto de demonstrar o fluxo ponta a ponta, foi construída uma interface funcional interativa utilizando a biblioteca Streamlit.

Fluxo de Execução da Aplicação:

1. **Entrada de Dados (Interface):** O usuário acessa a plataforma web e faz o upload de uma imagem da folha nos formatos permitidos (**.jpg**, **.jpeg**, **.png**, **.jfif**).
2. **Pré-processamento e Tratamento de Erros:** O sistema realiza a validação de formato da imagem utilizando a biblioteca Pillow. Caso a imagem original possua canais de transparência (formato RGBA ou modo P), o backend converte-a

automaticamente para o padrão RGB antes de salvar, evitando falhas de processamento nos motores de IA.

3. **Triagem de Integridade (Modelo Folha vs. Não-Folha):** O backend consome o primeiro modelo carregado em cache (`folha_naofolha.pt`) para verificar se a imagem enviada é de fato uma folha.
 - Se o modelo indicar que **não é uma folha** (ou se a confiança for baixa), o fluxo é interrompido imediatamente com um aviso na tela, bloqueando a análise de doenças para evitar diagnósticos falsos.
 - Se for validado como **uma folha**, o fluxo avança para a próxima etapa.
4. **Processamento com IA (Diagnóstico de Doenças):** A imagem validada é submetida ao segundo modelo (`best.pt`). O motor realiza a inferência e extrai de forma dinâmica a classe fitopatológica mais provável (`probs.top1`) e seu respectivo grau de certeza (`probs.top1conf`).
5. **Regras de Negócio e Tomada de Decisão:**
 - **Se a Confiança for < 50%:** O sistema bloqueia diagnósticos inseguros e exibe uma mensagem informando que não foi possível identificar a patologia com segurança, sugerindo o envio de uma nova imagem com melhor iluminação ou foco.
 - **Se a Confiança for ≥ 50%:** O sistema faz a correspondência da classe identificada com o dicionário interno de mapeamento agrônomo (`RECOMENDACOES`).
6. **Exibição dos Resultados (Saída Interpretável):** O sistema renderiza na tela de forma visual e amigável:
 - O Diagnóstico com a identificação da cultura e patologia detectada;
 - Uma Explicação agrônoma clara dos sinais identificados pela IA;
 - A Recomendação técnica de manejo imediato (ação a ser tomada pelo produtor);
 - Uma barra de progresso indicando visualmente o Grau de Confiança da predição.

5. Resultados, Limitações e Melhorias Futuras

O modelo final integrado, agora operando com a pipeline dupla (triagem de domínio + motor diagnóstico), demonstrou alta capacidade de generalização e assertividade. Conseguiu-se discernir de forma consistente entre variações sutis (como manchas foliares de Pinta Preta versus Requeima), enquanto o filtro estrutural eliminou a ocorrência de diagnósticos "falsos positivos" em imagens fora de contexto (objetos aleatórios).

Limitações Atuais do Sistema:

- **Sensibilidade ao Fundo:** Embora o sistema filtre imagens que não são folhas, a presença de elementos diversos no fundo de uma imagem válida (como solo exposto, dedos do usuário segurando a folha ou ferramentas de metal) ainda pode reduzir a confiança (*confidence score*) da classificação da doença.

- **Diagnóstico Único:** O sistema é limitado a classificar a patologia predominante da folha enviada, não realizando diagnósticos múltiplos simultâneos caso a planta apresente mais de uma deficiência ou doença na mesma amostra.

Melhorias Futuras:

- **Evolução da Arquitetura Visual:** Implementar a versão de detecção de objetos da rede YOLO (delimitando *bounding boxes* em cada mancha específica) para permitir múltiplos diagnósticos em uma mesma folha.
- **Expansão do Banco de Dados:** Ampliar o mapeamento fitopatológico para incluir outras culturas de alto impacto comercial no agronegócio, como soja, milho e café.
- **Integração com IA Generativa:** Conectar uma API de Modelo Generativo (utilizando a técnica RAG) ligada ao dicionário de recomendações, permitindo que o produtor rural tire dúvidas em tempo real através de um chat inteligente após receber o diagnóstico da folha.
- **Migração Mobile e Acesso Offline:** Evoluir a interface web atual para um aplicativo mobile nativo (por exemplo, utilizando React Native), permitindo que o produtor rural possa tirar a foto e receber o diagnóstico no meio da lavoura, otimizando o modelo para funcionar mesmo sem conexão com a internet.